UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

Análise Preditiva de Ações Baseada em Notícias

Antonio Lopes Jr

Monografia - MBA em Inteligência Artificial e Big Data

ICMC USP
SÃO CARLOS

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Antonio Lopes Jr

Análise Preditiva de Ações Baseada em Notícias

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientadora: Prof. Dr. Fernando Pereira dos Santos

Versão original

São Carlos

2026

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTE TRABALHO, POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO PARA FINS DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi, ICMC/USP, com os dados fornecidos pelo(a) autor(a)

S856m

Lopes Jr, Antonio
Análise Preditiva de Ações Baseada em Notícias / Antonio Lopes Jr ; orientador Fernando Pereira dos Santos. – São Carlos, 2026.
54 p. : il. (algumas color.) ; 30 cm.

Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2026.

1. LaTeX. 2. abnTeX. 3. Classe USPSC. 4. Editoração de texto. 5. Normalização da documentação. 6. Tese. 7. Dissertação. 8. Documentos (elaboração). 9. Documentos eletrônicos. I. Santos, Fernando Pereira, orient. II. Título.

Antonio Lopes Jr

Predictive Analysis of Stocks Based on News

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Prof. Dr. Fernando Pereira dos Santos

Original version

São Carlos

2026

RESUMO

LOPES JR, A. **Análise Preditiva de Ações Baseada em Notícias**. 2026. 54 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Apresentar, em resumo, a contextualização, motivação, lacunas, proposta, resultados, direções e conclusões. (1 parágrafo (+- 500 palavras)).

O resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. (. . .) Salientamos que algumas Unidades exigem o titulo dos trabalhos acadêmicos em inglês, tornando necessário a inclusão das referências nos resumos e abstracts, o que foi adotado no **Modelo para TCC em LaTeX utilizando a classe USPSC** e no **Modelo para teses e dissertações em LaTeX utilizando a classe USPSC**. As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto nbr6028.

Palavras-chave: LaTeX. Classe USPSC. Tese. Dissertação. Trabalho de conclusão de curso (TCC). Relatório.

ABSTRACT

LOPES JR, A. **Predictive Analysis of Stocks Based on News**. 2026. 54 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

This is the english abstract.

Keywords: LaTeX. USPSC class. Thesis. Dissertation. Conclusion course paper. Report.

LISTA DE FIGURAS

LISTA DE TABELAS

Tabela 1 – Síntese dos trabalhos relacionados 43

LISTA DE QUADROS

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
abnTeX	ABsurdas Normas para TeX
IBGE	Instituto Brasileiro de Geografia e Estatística
LaTeX	Lamport TeX
USP	Universidade de São Paulo
USPSC	Campus USP de São Carlos

SUMÁRIO

1 INTRODUÇÃO . . . 21
1.1 Problema . . . 21
1.2 Justificativa . . . 22
1.3 Objetivos . . . 22
1.3.1 Objetivo Geral . . . 22
1.3.2 Objetivos Específicos . . . 23
1.4 Delimitação do Escopo . . . 23
1.5 Estrutura do Trabalho . . . 23

2 FUNDAMENTAÇÃO TEÓRICA . . . 25
2.1 Mercado Financeiro Brasileiro . . . 25
2.1.1 Hipótese de Mercados Eficientes e Hipótese de Mercados Adaptativos . . . 25
2.2 Big Data e Mídias Sociais em Finanças . . . 26
2.2.1 Características de Big Data (Volume, Velocidade, Variedade) . . . 26
2.2.2 X/Twitter como Fonte de Dados Financeiros . . . 28
2.2.3 Desafios de Processamento de Dados Textuais Massivos . . . 30
2.3 Processamento de Linguagem Natural . . . 32
2.3.1 Conceitos Fundamentais e Paradigmas . . . 32
2.3.2 Pipeline de Processamento Textual . . . 33
2.3.3 Modelos de Linguagem e Transformers . . . 35
2.4 Análise de Sentimento . . . 36
2.4.1 Tarefas e Níveis de Análise . . . 36
2.4.2 Abordagens Metodológicas . . . 37
2.4.3 Análise de Sentimento no Domínio Financeiro em Português . . . 38
2.5 Trabalhos Relacionados . . . 39
2.5.1 Trabalhos Internacionais . . . 39
2.5.2 Trabalhos Nacionais . . . 40
2.5.3 Síntese Comparativa e Posicionamento do Presente Trabalho . . . 42

3 METODOLOGIA . . . 45

4 AVALIAÇÃO EXPERIMENTAL . . . 47

5 CONCLUSÕES . . . 49

REFERÊNCIAS . . . 51

1 INTRODUÇÃO

O mercado financeiro é intrinsecamente volátil, impulsionado não apenas por fundamentos econômicos, mas também por eventos políticos, macroeconômicos, regulatórios e pela percepção coletiva (sentimento) disseminada em dados não estruturados massivos, como notícias de imprensa e mídias sociais.

Embora a relação entre divulgação de resultados corporativos, indicadores macroeconômicos e movimentação de preços seja amplamente documentada, a influência do sentimento público capturado em notícias e mídias sociais sobre o comportamento dos ativos permanece menos compreendida e quantificada. O volume massivo e a alta velocidade (*volume* e *velocity*) de geração desses dados textuais não estruturados configuram um desafio típico de *Big Data*, excedendo a capacidade de análise humana em tempo real e criando assimetrias informacionais no mercado.

Estudos empíricos demonstram que termos com conotação de incerteza nas edições diárias do jornal Valor Econômico apresentam associação negativa estatisticamente significante com o retorno diário do Ibovespa, enquanto palavras com tom negativo correlacionam-se positivamente com o aumento da volatilidade do índice (GALDI; GONÇALVES, 2018), evidenciando o impacto quantificável do sentimento noticioso sobre a dinâmica de preços no mercado brasileiro.

1.1 Problema

Nesse contexto, emerge a seguinte questão de pesquisa: como estruturar e quantificar, em escala, a polaridade e o conteúdo semântico de publicações financeiras no X/Twitter para caracterizar o sentimento do mercado brasileiro?

Estudos internacionais já demonstraram que o sentimento expresso em mídias sociais mantém relação mensurável com o comportamento do mercado financeiro - Bollen, Mao e Zeng (2011), por exemplo, identificaram associação estatisticamente significante entre o humor coletivo expresso no Twitter e as variações do mercado de ações norte-americano. No entanto, análises robustas e validadas dessa relação para o mercado brasileiro ainda são escassas. As particularidades linguísticas do português brasileiro, a estrutura diferenciada do mercado de capitais nacional e a limitada disponibilidade de datasets rotulados de qualidade representam desafios específicos que dificultam a transferência direta de soluções desenvolvidas para outros contextos (Santos; Bianchi; Costa, 2023a).

A literatura nacional acerca do sentimento do investidor no mercado brasileiro permanece incipiente (GALDI; GONÇALVES, 2018), com poucos trabalhos dedicados à construção de modelos de PLN específicos para o domínio financeiro em português. Iniciati-

vas recentes, como o desenvolvimento do FinBERT-PT-BR (Santos; Bianchi; Costa, 2023a), representam avanços importantes ao treinar modelos baseados na arquitetura BERT com 1,4 milhão de textos financeiros em português, porém ainda enfrentam limitações quanto ao tamanho das bases de dados rotuladas (apenas 503 textos anotados manualmente).

1.2 Justificativa

A literatura nacional sobre análise de sentimento aplicada ao mercado financeiro permanece incipiente (GALDI; GONÇALVES, 2018), com poucos trabalhos dedicados ao desenvolvimento de ferramentas de PLN específicas para o domínio financeiro em português brasileiro. Essa lacuna é agravada pela limitada disponibilidade de datasets rotulados de qualidade, pelas particularidades linguísticas do português e pela estrutura diferenciada do mercado de capitais nacional, fatores que dificultam a simples transposição de soluções consolidadas em outros idiomas e mercados (Santos; Bianchi; Costa, 2023a).

Iniciativas recentes, como o FinBERT-PT-BR (Santos; Bianchi; Costa, 2023a), representam avanços relevantes, porém ainda enfrentam restrições quanto ao tamanho das bases de dados anotadas manualmente e à ausência de pipelines reproduzíveis que integrem coleta, pré-processamento e classificação de sentimento em um fluxo estruturado. O presente trabalho busca contribuir nessa direção, ao propor e documentar um pipeline de PLN de ponta a ponta voltado ao contexto financeiro brasileiro, oferecendo à comunidade acadêmica um protocolo metodológico replicável e passível de extensão em pesquisas futuras.

Do ponto de vista prático, a capacidade de monitorar e quantificar o sentimento disseminado em publicações de veículos especializados em tempo quase real representa um recurso relevante para analistas e gestores que buscam incorporar informações não estruturadas à sua leitura de mercado. A automação desse processo por meio de técnicas de aprendizado de máquina supera a limitação humana de processar grandes volumes de dados textuais com alta velocidade, reduzindo assimetrias informacionais e ampliando a qualidade da análise qualitativa do ambiente econômico.

1.3 Objetivos

1.3.1 Objetivo Geral

Desenvolver e validar pipeline de Processamento de Linguagem Natural (PLN) para análise de sentimento de publicações financeiras no X/Twitter, caracterizando padrões temporais e semânticos do discurso financeiro brasileiro.

1.3.2 Objetivos Específicos

1. Coletar e estruturar um dataset de publicações do X/Twitter dos veículos InfoMoney e Exame, abrangendo o período de outubro de 2025 a fevereiro de 2026;
2. Realizar Análise Exploratória dos Dados (AED) e aplicar técnicas de pré-processamento para detecção e remoção de dados redundantes e valores atípicos (*outliers*);
3. Desenvolver um pipeline de pré-processamento e análise de sentimento baseado em PLN para classificação da polaridade dos textos coletados;
4. Avaliar e comparar o desempenho de diferentes abordagens de classificação de sentimento - baseadas em léxico e em modelos de linguagem pré-treinados - no domínio financeiro em português brasileiro;
5. Caracterizar descritivamente o dataset resultante, identificando a distribuição de polaridade e os padrões semânticos predominantes no discurso financeiro dos veículos analisados.

1.4 Delimitação do Escopo

Como *proxy* para captura de sentimento de mercado, serão utilizadas publicações da rede social X (anteriormente Twitter) de veículos especializados em economia e finanças: InfoMoney e Exame. O período de análise compreenderá publicações entre 10 de outubro de 2025 e 6 de fevereiro de 2026, totalizando aproximadamente quatro meses de dados.

A delimitação desse recorte temporal decorre de um conjunto de restrições metodológicas e operacionais: (i) o acesso à API do X/Twitter está condicionado a planos comerciais com janelas históricas limitadas, inviabilizando a coleta retroativa de grandes volumes de dados sem custos elevados; e (ii) o custo de acesso a planos de API com maior capacidade de recuperação histórica representa uma barreira concreta para pesquisas acadêmicas sem financiamento dedicado. Reconhece-se que esse recorte constitui uma limitação do estudo, cujos impactos serão discutidos no Capítulo 5.

A escolha por posts em detrimento de artigos completos fundamenta-se em aspectos metodológicos: (i) maior facilidade de extração estruturada de dados via API, dispensando técnicas complexas de *web scraping*; e (ii) formato textual conciso e objetivo, mais adequado para análise de polaridade semântica.

1.5 Estrutura do Trabalho

Este trabalho está organizado em cinco capítulos. O Capítulo 1 apresenta a contextualização do problema, a questão de pesquisa, a identificação do gap na literatura nacional, a justificativa e os objetivos geral e específicos da pesquisa.

O Capítulo 2 apresenta a revisão de literatura, abordando os fundamentos de Processamento de Linguagem Natural (PLN), as principais abordagens de análise de sentimento aplicadas ao mercado financeiro e os trabalhos relevantes desenvolvidos para o contexto brasileiro e para a língua portuguesa.

O Capítulo 3 descreve em detalhes a metodologia proposta, incluindo: o processo de coleta de dados via API do X/Twitter; a análise exploratória e o tratamento do dataset; e o pipeline de PLN para extração de features semânticas e classificação de polaridade dos textos coletados.

O Capítulo 4 apresenta os resultados da análise de sentimento realizada, incluindo a caracterização descritiva do dataset, os padrões temporais e semânticos identificados no discurso financeiro dos veículos analisados e a discussão dos achados à luz da literatura.

Por fim, o Capítulo 5 sintetiza as principais conclusões do trabalho, discute as contribuições científicas e práticas da pesquisa, apresenta as limitações encontradas e sugere direcionamentos para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta o referencial teórico que sustenta o presente trabalho. A construção do arcabouço conceitual parte da teoria de mercados financeiros — em especial da Hipótese de Mercados Adaptativos (Lo, 2004), que reconhece o papel das emoções e dos comportamentos coletivos na formação dos preços — e avança pelas bases técnicas que viabilizam a análise proposta: o fenômeno do *Big Data* e a emergência das mídias sociais como fonte de dados financeiros (Laney, 2001; Bollen; Mao; Zeng, 2011), os fundamentos do Processamento de Linguagem Natural (Caseli; Nunes; Pagano, 2024; Jurafsky; Martin, 2026) e as abordagens metodológicas da Análise de Sentimento aplicadas ao domínio financeiro em língua portuguesa (Kearney; Liu, 2014; Santos; Bianchi; Costa, 2023b). O capítulo encerra com uma revisão dos principais trabalhos relacionados, situando esta pesquisa na literatura nacional e internacional da área.

2.1 Mercado Financeiro Brasileiro

O mercado financeiro brasileiro é organizado em torno da B3 (Brasil, Bolsa, Balcão), que concentra a negociação de ações, derivativos, títulos de renda fixa e câmbio em uma única infraestrutura integrada. Em termos de capitalização e liquidez, a B3 figura entre as principais bolsas de valores da América Latina, sendo amplamente utilizada como referência para estudos empíricos sobre o comportamento de ativos em mercados emergentes (Jr., 1994; Yoshinaga; Castro, 2012). A dinâmica desse mercado é influenciada por um conjunto heterogêneo de fatores — fundamentos macroeconômicos, decisões de política monetária, eventos políticos e, crescentemente, o fluxo contínuo de informações e opiniões veiculadas por meios digitais — o que torna a análise de sentimento uma ferramenta potencialmente relevante para compreender os movimentos coletivos dos investidores.

2.1.1 Hipótese de Mercados Eficientes e Hipótese de Mercados Adaptativos

A Hipótese de Mercados Eficientes (HME), formulada por Fama (1970) e consolidada em sua versão revisada por Fama (1991), postula que os preços dos ativos financeiros refletem, a qualquer momento, toda a informação disponível relevante. Em sua forma semiforte, a HME implica que nenhuma análise de informações públicas — incluindo notícias, relatórios ou declarações de agentes econômicos — seria capaz de gerar retornos sistematicamente superiores ao mercado, uma vez que essas informações já estariam incorporadas aos preços de forma quase instantânea (Fama, 1970; Grossman; Stiglitz, 1980).

A HME, contudo, foi progressivamente desafiada por evidências empíricas de anomalias de mercado — como sobrereação e subreação a eventos, efeito momentum e

reversão à média — que não se encaixam no paradigma de plena eficiência informacional (Jr., 1994). No contexto brasileiro, Jr. (1994) documentaram evidências de sobrereação no mercado acionário nacional, sugerindo que investidores locais respondem de forma excessiva a notícias recentes, padrão consistente com a influência de fatores comportamentais e emocionais nas decisões de investimento.

Em resposta a essas limitações, Lo (2004, 2005) propôs a Hipótese de Mercados Adaptativos (HMA), que reinterpreta a eficiência de mercado sob uma perspectiva evolucionária. Segundo a HMA, os agentes financeiros não são racionais no sentido neoclássico estrito, mas adaptam seu comportamento continuamente em resposta ao ambiente de mercado, incorporando heurísticas, emoções e aprendizado social em suas decisões (Lo, 2004). Essa perspectiva é particularmente relevante para o presente trabalho: se os preços dos ativos refletem não apenas informações objetivas, mas também o estado emocional e as expectativas coletivas dos agentes — conforme previsto pela HMA — então o sentimento expresso em publicações do X/Twitter constitui um sinal informacional potencialmente relevante para compreender o humor do mercado financeiro brasileiro (Lo, 2004; Bollen; Mao; Zeng, 2011; Santos; Bianchi; Costa, 2023b). Não por acaso, Santos; Bianchi; Costa (2023b) invocam explicitamente a HMA como fundamento teórico do FinBERT-PT-BR, situando a análise de sentimento como ferramenta de captura das "emoções refletidas nos textos" que influenciam as decisões dos agentes no mercado adaptativo.

2.2 Big Data e Mídias Sociais em Finanças

A expansão das plataformas digitais nas últimas duas décadas transformou profundamente a natureza dos dados disponíveis para a pesquisa em finanças. Se, historicamente, os estudos empíricos dependiam de séries temporais de preços, volumes e indicadores contábeis gerados em ciclos regulares, a consolidação das mídias sociais e dos ambientes de comunicação em tempo real produziu um novo tipo de dado — massivo, contínuo, heterogêneo e predominantemente textual — cujo potencial informacional para a compreensão do comportamento dos mercados ainda está sendo explorado (Kearney; Liu, 2014; Mayer-Schönberger; Cukier, 2013). Esta seção caracteriza esse fenômeno sob o conceito de *Big Data*, examina o papel específico do X/Twitter como fonte de dados financeiros e discute os principais desafios metodológicos que emergem do processamento de grandes volumes de texto financeiro em língua portuguesa.

2.2.1 Características de Big Data (Volume, Velocidade, Variedade)

O termo *Big Data* ganhou relevância científica e empresarial a partir do trabalho de Laney (2001), analista do META Group, que identificou três dimensões fundamentais impulsionadas pela explosão do comércio eletrônico no início dos anos 2000: **volume**, **velocidade** e **variedade** - o chamado modelo dos "3 Vs". Embora o conceito tenha

evoluído desde então, incorporando dimensões adicionais como veracidade e valor (Mayer-Schönberger; Cukier, 2013; Chen; Mao; Liu, 2014), os três eixos originais continuam sendo a base conceitual mais adotada na literatura para caracterizar fenômenos de dados em larga escala.

De maneira geral, *Big Data* pode ser definido como a capacidade de coletar, armazenar e analisar conjuntos de dados cujo tamanho, ritmo de geração ou complexidade superam as capacidades dos sistemas gerenciadores de banco de dados relacionais (RDBMS) e das arquiteturas convencionais de *data warehouse*, projetados para dados estruturados em volumes previsíveis e processamento em lote (Mayer-Schönberger; Cukier, 2013; Chen; Mao; Liu, 2014). Para Chen; Mao; Liu (2014), essa definição é operacionalizada precisamente por meio dos "3 Vs", que descrevem, respectivamente, a magnitude dos dados produzidos, a rapidez com que precisam ser processados e a heterogeneidade dos formatos em que se apresentam.

Volume refere-se à quantidade absoluta de dados gerados, armazenados e processados. O crescimento exponencial da produção digital — impulsionado por dispositivos conectados, plataformas de mídias sociais, sensores e transações eletrônicas — fez com que a escala de dados relevantes passasse de gigabytes para terabytes e, atualmente, para petabytes e exabytes (Mayer-Schönberger; Cukier, 2013). No contexto financeiro, essa dimensão se manifesta, por exemplo, no volume de ordens de compra e venda negociadas eletronicamente em bolsas de valores, nos registros de operações de alta frequência (*high-frequency trading*) e nas centenas de milhões de publicações diárias em plataformas digitais que tangenciam temas econômicos e financeiros (Bollen; Mao; Zeng, 2011; Ranco *et al.*, 2015).

Velocidade diz respeito ao ritmo de geração e à necessidade de processamento dos dados em tempo real ou quase real (Laney, 2001). Em mercados financeiros, a velocidade é uma dimensão especialmente crítica: informações sobre eventos macroeconômicos, decisões de bancos centrais ou crises corporativas se propagam em milissegundos por redes digitais globais, alterando o comportamento dos investidores e os preços dos ativos antes mesmo que analistas humanos possam interpretar os eventos e antes que sistemas convencionais de processamento em lote (*batch processing*) concluam seus ciclos de atualização (Chen; Mao; Liu, 2014). Plataformas como o X (antigo Twitter) exemplificam essa dimensão ao produzirem fluxos contínuos de publicações que, conforme demonstrado por Bollen; Mao; Zeng (2011), carregam informações sobre o humor coletivo capazes de antecipar movimentos no índice Dow Jones Industrial Average (DJIA). A análise em tempo real desses fluxos exige infraestrutura computacional capaz de ingerir e processar *streams* de dados de maneira contínua, o que distingue esses sistemas das abordagens convencionais de processamento em lote (*batch processing*).

Variedade refere-se à diversidade de formatos, estruturas e fontes dos dados

disponíveis. Enquanto sistemas de informação tradicionais lidam predominantemente com dados estruturados — organizados em tabelas com campos e tipos definidos — o ecossistema digital contemporâneo produz volumes massivos de dados semiestruturados (como arquivos JSON e XML) e não estruturados (como textos livres, imagens, vídeos e publicações em redes sociais) (Laney, 2001; Mayer-Schönberger; Cukier, 2013). No domínio financeiro, essa variedade é particularmente desafiadora: análises quantitativas baseadas em séries temporais de preços e volumes coexistem com informações qualitativas extraídas de notícias, relatórios corporativos, comunicados de política monetária e conversações em plataformas de mídias sociais (Kearney; Liu, 2014). Integrar essas fontes heterogêneas em modelos preditivos unificados constitui um dos principais desafios metodológicos do campo, como discutido nas seções subsequentes deste trabalho.

Além dos três eixos originais, a literatura recente tem proposto extensões ao modelo. A dimensão de **veracidade** aborda a incerteza inerente à qualidade e à confiabilidade dos dados, tema especialmente relevante em ambientes de mídias sociais, onde informações falsas, rumores e ruído informacional se misturam a sinais genuínos (Chen; Mao; Liu, 2014). A dimensão de **valor** ressalta que o simples acúmulo de dados não produz *insights* por si só: é necessário transformá-los em conhecimento acionável por meio de técnicas analíticas adequadas (Mayer-Schönberger; Cukier, 2013). No contexto desta dissertação, ambas as dimensões são diretamente relevantes, pois a extração de sinais de sentimento de textos financeiros em língua portuguesa demanda tanto mecanismos de filtragem de ruído quanto abordagens analíticas especializadas capazes de produzir um índice de sentimento coerente e interpretável.

A emergência do *Big Data* redefiniu a fronteira do que é computacionalmente viável na pesquisa em finanças comportamentais. Se, por décadas, a análise empírica em finanças esteve restrita a dados estruturados de alta precisão — preços, volumes, indicadores contábeis — a disponibilidade de conjuntos massivos de dados textuais abriu uma nova agenda de pesquisa centrada na extração automatizada de sentimento a partir de fontes digitais (Kearney; Liu, 2014; Antweiler; Frank, 2004). É nesse contexto que se insere o presente trabalho: a interseção entre o volume, a velocidade e a variedade característicos das publicações financeiras no X/Twitter e as técnicas de Processamento de Linguagem Natural (PLN) discutidas no Capítulo 2, especialmente os modelos baseados em *transformers* adaptados ao domínio financeiro em língua portuguesa.

2.2.2 X/Twitter como Fonte de Dados Financeiros

A utilização de plataformas digitais de comunicação como fonte de dados para análise de mercados financeiros precede o surgimento do X/Twitter. O trabalho pioneiro de Antweiler; Frank (2004) demonstrou que mensagens publicadas em fóruns de discussão financeira — especificamente no Yahoo Finance e no Raging Bull — continham informação

relevante sobre o comportamento futuro dos preços de ações. Analisando aproximadamente 1,5 milhão de mensagens relativas a 45 empresas listadas no Dow Jones Industrial Average e no Dow Jones Internet Index entre 1999 e 2001, os autores encontraram evidências de que o volume de mensagens ajudava a prever a volatilidade do mercado, ao passo que o conteúdo dessas mensagens apresentava relação estatisticamente significativa com retornos subsequentes. Embora o efeito sobre retornos fosse economicamente modesto, o estudo estabeleceu o precedente metodológico central para a área: textos gerados por usuários em plataformas digitais carregam conteúdo informacional com implicações para a dinâmica dos preços de ativos.

A ascensão do X/Twitter — plataforma lançada em 2006 e que rapidamente se tornou um dos principais canais de comunicação em tempo real no mundo — deslocou o foco da pesquisa dos fóruns especializados para as redes sociais de uso geral. A arquitetura da plataforma, baseada em publicações curtas (*tweets*) de até 280 caracteres, cronológicas e públicas, criou um ambiente propício à disseminação veloz de informações financeiras, opiniões de mercado e reações a eventos econômicos (Sprenger *et al.*, 2014). Diferentemente dos fóruns de investidores, o X/Twitter agrega uma audiência heterogênea — analistas institucionais, investidores individuais, jornalistas e o público geral — o que amplia tanto o volume de dados disponíveis quanto a diversidade de perspectivas capturadas (Mao; Counts; Bollen, 2011).

O marco central para a consolidação do X/Twitter como objeto de pesquisa em finanças foi o estudo de Bollen; Mao; Zeng (2011). Os autores analisaram o conteúdo emocional de cerca de 9,7 milhões de *tweets* publicados entre abril e dezembro de 2008, aplicando duas ferramentas de análise de humor: o OpinionFinder, que mede valência positiva e negativa, e o GPOMS (*Google-Profile of Mood States*), que decompõe o estado de humor coletivo em seis dimensões — Calma, Alerta, Certeza, Vitalidade, Gentileza e Felicidade. Por meio de análise de causalidade de Granger e de uma rede neural *fuzzy* auto-organizável, os autores demonstraram que a dimensão "Calma" do GPOMS apresentava causalidade preditiva sobre os valores de fechamento do DJIA com defasagem de dois a seis dias, alcançando acurácia de 87,6% na previsão de movimentos diários de alta e baixa do índice. Esse resultado forneceu evidência empírica robusta de que o humor coletivo expresso em mídias sociais contém informação antecipatória sobre o comportamento do mercado, conectando a hipótese de influência do sentimento do investidor (Baker; Wurgler, 2007) ao ambiente digital das redes sociais.

Estudos posteriores ampliaram e refinaram essa linha de investigação. Sprenger *et al.* (2014) examinaram especificamente *tweets* com conteúdo financeiro — identificados pelo uso de *cashtags* (símbolo $ seguido do *ticker* da ação) — e encontraram que tanto o sentimento quanto o volume de publicações relacionadas a uma empresa eram preditivos de retornos e volume de negociação nos dias subsequentes, com efeito mais pronunciado

para ações de menor capitalização. Mao; Counts; Bollen (2011), por sua vez, compararam o poder preditivo de *tweets* financeiros com o de buscas no Google Trends, concluindo que a combinação das duas fontes superava qualquer uma isoladamente na previsão de retornos do S&P 500. Já Ranco *et al.* (2015) investigaram a relação entre o volume e o sentimento de *tweets* e os retornos das 30 empresas componentes do DJIA, identificando que o impacto do sentimento no Twitter é especialmente significativo nos dias que antecedem e sucedem eventos corporativos relevantes, como divulgação de resultados e anúncios de fusões.

No contexto brasileiro, a adoção do X/Twitter como fonte de dados financeiros apresenta particularidades relevantes para o presente trabalho. O Brasil figura historicamente entre os países com maior base de usuários da plataforma na América Latina, o que garante um volume substancial de publicações em língua portuguesa com conteúdo relacionado ao mercado financeiro e aos índices da B3. Contudo, a predominância de modelos de análise de sentimento treinados em inglês cria uma lacuna metodológica significativa: léxicos e modelos desenvolvidos para o inglês financeiro — como o dicionário de Loughran; McDonald (2011) — não capturam adequadamente as nuances semânticas e o vocabulário específico do mercado financeiro brasileiro, demandando o desenvolvimento ou adaptação de ferramentas especializadas para o português (Santos; Bianchi; Costa, 2023b). É precisamente essa lacuna que motiva a adoção do modelo FinBERT-PT-BR como ferramenta central de análise de sentimento neste trabalho, conforme detalhado na Seção 2.4.

2.2.3 Desafios de Processamento de Dados Textuais Massivos

A disponibilidade de grandes volumes de dados textuais provenientes de plataformas digitais não implica, por si só, a capacidade de extrair deles informação financeiramente relevante. Entre a coleta bruta de publicações e a geração de sinais de sentimento interpretáveis residem desafios técnicos e linguísticos substanciais, cuja superação constitui um dos problemas centrais da área (Kearney; Liu, 2014). Esses desafios podem ser agrupados em quatro dimensões interdependentes: ruído e qualidade dos dados, especificidade do vocabulário financeiro, escassez de recursos para línguas não inglesas e limitações das abordagens de análise disponíveis.

O primeiro e mais imediato desafio é a razão sinal-ruído característica das mídias sociais. Em plataformas como o X/Twitter, apenas uma fração das publicações que mencionam termos financeiros carrega informação genuinamente relevante para o comportamento dos ativos (Bollen; Mao; Zeng, 2011). O restante é composto por ruído informacional de diversas naturezas: *spam* automatizado, publicações de robôs (*bots*), comentários irônicos ou sarcásticos cuja polaridade real é oposta à aparente, e menções ambíguas em que o mesmo termo assume sentidos distintos conforme o contexto. A ironia e o sarcasmo são particularmente problemáticos para sistemas de análise de sentimento baseados em léxicos,

pois invertem a valência das palavras sem alterá-las formalmente (Liu; Zheng; Song, 2020). Além disso, a linguagem informal predominante nas redes sociais — repleta de abreviações, neologismos, emojis e erros ortográficos — exige etapas de pré-processamento robustas que normalizem o texto antes de qualquer análise semântica (Sousa *et al.*, 2025).

O segundo desafio diz respeito à especificidade do vocabulário financeiro. Um dos achados mais influentes nessa área foi demonstrado por Loughran; McDonald (2011), ao analisar a aplicação do dicionário Harvard General Inquirer — léxico de propósito geral amplamente utilizado em ciências sociais — a relatórios anuais de empresas (formulários 10-K). Os autores identificaram que aproximadamente três quartos das palavras classificadas como negativas por esse dicionário não carregavam conotação negativa no contexto financeiro: termos como *"liability"*, *"tax"* e *"depreciation"* são tecnicamente neutros ou simplesmente descritivos no vocabulário contábil-financeiro, mas aparecem como negativos em léxicos de uso geral. Essa discrepância motivou o desenvolvimento do dicionário Loughran-McDonald, específico para o domínio financeiro em inglês, e evidenciou que a transferência direta de ferramentas de PLN de propósito geral para o domínio financeiro produz resultados sistematicamente distorcidos (Loughran; McDonald, 2011; Kearney; Liu, 2014).

No contexto brasileiro, essa limitação se desdobra em uma terceira dimensão: a escassez de recursos linguísticos especializados para o português financeiro. Enquanto o inglês dispõe de léxicos validados (Loughran; McDonald, 2011), corpora anotados e modelos de linguagem pré-treinados em grandes volumes de texto financeiro, o português — e em particular o vocabulário do mercado financeiro brasileiro — permanece subrepresentado nos recursos disponíveis (Sousa *et al.*, 2025). Os estudos aplicados ao mercado brasileiro têm documentado sistematicamente essa lacuna: Falcão (2020), ao analisar notícias do Valor Econômico e da Folha de São Paulo entre 2013 e 2019 e relacioná-las ao comportamento do Ibovespa, e Lucas; Peixoto (2025), ao aplicar os léxicos VADER e HIV a notícias do mercado brasileiro coletadas via Google News API, constataram que dicionários desenvolvidos para o inglês capturam apenas parcialmente a variância dos índices brasileiros, com o percentual explicado pelos léxicos genéricos permanecendo relativamente baixo. A necessidade de recursos especializados para o português financeiro motivou iniciativas como a expansão automática de léxicos por técnicas de Word2Vec e Informação Mútua Pontual (PMI) (Sousa *et al.*, 2025) e, mais recentemente, o desenvolvimento do modelo FinBERT-PT-BR, treinado sobre 1,4 milhão de textos financeiros em português (Santos; Bianchi; Costa, 2023b).

O quarto desafio refere-se às limitações inerentes às abordagens disponíveis para processamento em escala. As duas grandes famílias de métodos — abordagens baseadas em léxicos e abordagens baseadas em aprendizado de máquina — apresentam compromissos distintos entre interpretabilidade, custo computacional e desempenho (Kearney; Liu,

2014). Abordagens léxicas são transparentes e dispensam dados rotulados, mas falham diante de ironia, negação e vocabulário não coberto pelo léxico. Abordagens baseadas em aprendizado de máquina — especialmente modelos profundos baseados em *transformers* — alcançam desempenho superior, mas exigem grandes volumes de dados anotados, que são escassos no domínio financeiro em português (Liu; Zheng; Song, 2020; Santos; Bianchi; Costa, 2023b). Além disso, o processamento de fluxos contínuos de *tweets* em tempo real impõe restrições de latência que podem inviabilizar modelos computacionalmente custosos sem infraestrutura adequada (Silva *et al.*, 2025). A superação desse conjunto de desafios demanda, portanto, não apenas avanços algorítmicos, mas também a construção cumulativa de recursos linguísticos e computacionais específicos para o domínio financeiro em português, agenda à qual o presente trabalho busca contribuir por meio da adoção e avaliação do FinBERT-PT-BR aplicado às publicações do X/Twitter.

2.3 Processamento de Linguagem Natural

O Processamento de Linguagem Natural (PLN) é o campo de pesquisa que investiga e propõe métodos e sistemas para o tratamento computacional da linguagem humana (Caseli; Nunes; Pagano, 2024). Situado na interseção entre a Ciência da Computação, a Inteligência Artificial e a Linguística, o PLN abrange desde tarefas de baixo nível — como segmentação de texto em palavras e identificação de classes gramaticais — até tarefas de alta complexidade semântica, como tradução automática, resposta a perguntas e análise de sentimento (Jurafsky; Martin, 2026). Para os fins deste trabalho, o PLN constitui o conjunto de técnicas que viabiliza a extração automatizada de sentimento a partir de publicações textuais do X/Twitter relacionadas ao mercado financeiro brasileiro, transformando dados não estruturados em classificações de polaridade que expressam o humor coletivo dos investidores.

2.3.1 Conceitos Fundamentais e Paradigmas

A linguagem natural apresenta desafios computacionais que a distinguem fundamentalmente de outros tipos de dados: é ambígua, dependente de contexto, culturalmente situada e semanticamente densa (Caseli; Nunes; Pagano, 2024). Uma mesma sequência de palavras pode admitir interpretações radicalmente distintas conforme o contexto discursivo em que é produzida, e o significado de uma expressão frequentemente depende de conhecimento de mundo que não está explicitamente codificado no texto. Essas propriedades fazem com que o processamento completo e adequado da língua continue sendo um dos problemas abertos mais desafiadores da Inteligência Artificial (Caseli; Nunes; Pagano, 2024; Jurafsky; Martin, 2026).

Ao longo de sua história, o PLN organizou-se em torno de três grandes paradigmas (Caseli; Nunes; Pagano, 2024). O **paradigma simbólico**, dominante até a década de 1980,

representa o conhecimento linguístico de forma explícita por meio de léxicos, gramáticas e regras lógicas construídas manualmente por especialistas. Embora ofereça alta interpretabilidade e precisão em domínios bem definidos, essa abordagem não escala para a diversidade e a variabilidade da linguagem em uso real. O **paradigma estatístico**, que ganhou proeminência nos anos 1990 com o aumento da capacidade computacional e a disponibilidade de grandes corpora digitais, substituiu as regras explícitas por modelos probabilísticos aprendidos a partir de dados. Fenômenos linguísticos passaram a ser representados em termos de frequências de coocorrência e distribuições condicionais, com destaque para os modelos de *n-gramas* e os classificadores baseados em aprendizado de máquina raso (*shallow learning*) (Jurafsky; Martin, 2026). O **paradigma neural**, que se consolidou a partir de meados dos anos 2010, introduziu arquiteturas de redes neurais profundas capazes de aprender representações distribuídas da língua diretamente a partir de texto bruto, sem a necessidade de engenharia de *features* manual. Esse paradigma atingiu seu apogeu com o desenvolvimento dos modelos de linguagem baseados em *transformers* (Jurafsky; Martin, 2026), que estabeleceram novos estados da arte em praticamente todas as tarefas de PLN e são hoje a base dos sistemas de maior desempenho em análise de sentimento financeiro (Santos; Bianchi; Costa, 2023b).

Na prática, aplicações contemporâneas de PLN frequentemente adotam abordagens **híbridas**, combinando o conhecimento explícito do paradigma simbólico — como léxicos especializados de domínio — com a capacidade generalizante dos modelos neurais (Caseli; Nunes; Pagano, 2024; Kearney; Liu, 2014). No domínio financeiro em português, essa hibridização é especialmente relevante dado o vocabulário técnico específico do mercado brasileiro, que pode não estar adequadamente representado em modelos de linguagem treinados em corpora genéricos (Sousa *et al.*, 2025; Santos; Bianchi; Costa, 2023b).

2.3.2 Pipeline de Processamento Textual

A extração de informação semântica a partir de textos brutos segue, em geral, um conjunto de etapas encadeadas conhecido como *pipeline* de PLN. Cada etapa transforma a representação do texto, progressivamente reduzindo o ruído e aumentando a estrutura disponível para as etapas subsequentes (Jurafsky; Martin, 2026; Caseli; Nunes; Pagano, 2024). No contexto de análise de sentimento de publicações do X/Twitter, as principais etapas são as seguintes.

A **coleta e armazenamento** constitui o ponto de entrada do *pipeline*. No caso de dados do X/Twitter, isso envolve o acesso à API da plataforma e a estruturação dos dados brutos — que chegam em formato JSON semiestruturado — em um formato adequado para processamento (Freitas, 2024). Metadados como data de publicação, identificador do usuário e métricas de engajamento (*likes*, *retweets*) são preservados para análises subsequentes.

A **tokenização** é o processo de segmentar o texto em unidades mínimas de processamento, denominadas *tokens* (Jurafsky; Martin, 2026). Em textos de redes sociais, a tokenização apresenta desafios particulares: *hashtags*, *cashtags* (e.g., `$PETR4`), menções (`@usuário`), emojis e abreviações informais são elementos que tokenizadores projetados para texto formal tendem a tratar de maneira inadequada. Tokenizadores especializados para o domínio de redes sociais, ou os próprios tokenizadores internos dos modelos *transformer* (baseados em *subword tokenization* como *WordPiece* ou *Byte-Pair Encoding*), são mais adequados para esse tipo de dado (Jurafsky; Martin, 2026; Santos; Bianchi; Costa, 2023b).

A **normalização e limpeza** compreende um conjunto de transformações que reduzem a variabilidade superficial do texto sem alterar seu conteúdo semântico relevante. Para textos financeiros do Twitter, isso tipicamente inclui: remoção de URLs, conversão para minúsculas, tratamento de caracteres especiais e normalização de entidades financeiras (*tickers*, siglas de índices). Em abordagens baseadas em léxicos, etapas adicionais como **remoção de palavras funcionais** (*stopwords*), **lematização** — redução de formas flexionadas à forma canônica da palavra — e **stemização** — truncamento do sufixo para obtenção do radical — são aplicadas para reduzir a dimensionalidade do vocabulário (Caseli; Nunes; Pagano, 2024; Sousa *et al.*, 2025). Em modelos *transformer* como o BERT, essas etapas são parcialmente dispensáveis, pois o modelo aprende representações contextualizadas que capturam variações morfológicas automaticamente (Jurafsky; Martin, 2026).

A **representação vetorial** (*embedding*) é a etapa em que o texto processado é convertido em representações numéricas que capturam relações semânticas entre palavras e sentenças (Jurafsky; Martin, 2026). A evolução nessa etapa reflete a progressão dos paradigmas do PLN: das representações esparsas baseadas em frequências (*bag-of-words*, TF-IDF) às representações densas aprendidas por modelos neurais (*word2vec*, GloVe) e, mais recentemente, às representações contextualizadas produzidas por modelos de linguagem de grande escala baseados em *transformers*, em que o vetor de uma palavra é função de todo o contexto em que ela ocorre (Jurafsky; Martin, 2026; Santos; Bianchi; Costa, 2023b).

A **classificação ou extração** constitui a etapa final do *pipeline*, em que as representações vetoriais são utilizadas como entrada para modelos que realizam a tarefa de interesse — no caso deste trabalho, a classificação do sentimento de cada publicação em polaridades (positiva, negativa ou neutra) (Claro *et al.*, 2024). A qualidade dessa etapa depende criticamente da adequação das etapas anteriores e da representatividade dos dados de treinamento do modelo em relação ao domínio e à língua-alvo (Kearney; Liu, 2014; Loughran; McDonald, 2011).

2.3.3 Modelos de Linguagem e Transformers

A arquitetura *Transformer*, introduzida por Vaswani *et al.* (2017) no artigo "Attention Is All You Need", representou uma ruptura fundamental no campo do PLN. Diferentemente das arquiteturas recorrentes (RNN, LSTM) que processavam sequências de forma serial, o *Transformer* opera em paralelo sobre toda a sequência de entrada por meio de um mecanismo de **atenção** (*self-attention*), que pondera a relevância de cada *token* em relação a todos os outros (Jurafsky; Martin, 2026). Isso permitiu tanto um treinamento significativamente mais eficiente em grandes corpora quanto uma captura mais rica de dependências de longo alcance na língua.

O modelo BERT (*Bidirectional Encoder Representations from Transformers*), proposto por Devlin *et al.* (2019), consolidou o paradigma de **pré-treinamento e ajuste fino** (*pre-training and fine-tuning*) como o estado da arte em PLN. Na fase de pré-treinamento, o BERT é treinado em tarefas auto-supervisionadas sobre grandes volumes de texto não rotulado — *Masked Language Modeling* (MLM), em que o modelo aprende a prever tokens mascarados com base no contexto bidirecional, e *Next Sentence Prediction* (NSP) — adquirindo representações linguísticas ricas e generalizáveis (Jurafsky; Martin, 2026). Na fase de ajuste fino (*fine-tuning*), o modelo pré-treinado é especializado para uma tarefa específica — como classificação de sentimento — com um número relativamente pequeno de exemplos rotulados, transferindo o conhecimento linguístico adquirido na fase anterior (Santos; Bianchi; Costa, 2023b).

Para o domínio financeiro em inglês, Araci (2019) desenvolveram o FinBERT, um modelo BERT especializado por meio de ajuste fino em textos financeiros, que demonstrou desempenho superior ao BERT genérico em tarefas de análise de sentimento financeiro. Essa abordagem evidenciou que a especialização de domínio — o pré-treinamento ou ajuste fino com textos específicos da área — é um fator determinante para o desempenho em linguagem técnica (Araci, 2019; Santos; Bianchi; Costa, 2023b).

No contexto brasileiro, o modelo **BERTimbau** (Souza; Nogueira; Lotufo, 2020) forneceu a base para a especialização em português: trata-se de um BERT pré-treinado sobre um corpus de 2,68 bilhões de palavras em português, cobrindo fontes jornalísticas, enciclopédicas e da *web*. A partir do BERTimbau, Santos; Bianchi; Costa (2023b) desenvolveram o **FinBERT-PT-BR**, realizando ajuste fino sobre 1,4 milhão de sentenças de notícias financeiras em português coletadas do Valor Econômico, Exame e InfoMoney entre 2006 e 2022. O modelo resultante — e sua variante para classificação de sentimento, o **SentFinBERT-PT-BR** — apresentou desempenho superior aos modelos anteriores do estado da arte em português para a tarefa de análise de sentimento de textos financeiros, sendo adotado neste trabalho como a principal ferramenta de extração de polaridade das publicações do X/Twitter relacionadas aos índices da B3.

2.4 Análise de Sentimento

A Análise de Sentimento (AS), também denominada mineração de opinião (*opinion mining*), é a área do PLN dedicada à identificação e extração computacional de opiniões, sentimentos, emoções e atitudes expressas em textos não estruturados (Liu; Zheng; Song, 2020). O objetivo central da AS é determinar a **polaridade** de um dado conteúdo — se ele expressa uma orientação positiva, negativa ou neutra — podendo operar em diferentes níveis de granularidade: no nível do documento, da sentença ou de aspectos específicos do texto (Jurafsky; Martin, 2026; Liu; Zheng; Song, 2020). No domínio financeiro, a AS adquire relevância particular ao permitir mensurar a percepção coletiva dos agentes econômicos — expressa em notícias, relatórios e publicações em redes sociais — fornecendo um indicador qualitativo do humor do mercado que complementa as métricas quantitativas tradicionais (Kearney; Liu, 2014; Tetlock, 2007).

2.4.1 Tarefas e Níveis de Análise

A AS pode ser organizada em torno de três tarefas principais, que diferem em complexidade e granularidade (Liu; Zheng; Song, 2020; Jurafsky; Martin, 2026). A **classificação de polaridade** é a tarefa mais diretamente relevante para este trabalho: dado um texto, o sistema atribui-lhe uma categoria de sentimento — positivo, negativo ou neutro. Em contextos financeiros, essa classificação frequentemente se traduz em sinais de otimismo ou pessimismo do investidor em relação a um ativo ou ao mercado como um todo (Bollen; Mao; Zeng, 2011; Galdi; Gonçalves, 2018). A **análise de sentimento baseada em aspectos** (*aspect-based sentiment analysis*) vai além da polaridade global e identifica o sentimento associado a entidades ou atributos específicos mencionados no texto — por exemplo, distinguindo a avaliação sobre a gestão de uma empresa de sua avaliação sobre seus resultados financeiros (Liu; Zheng; Song, 2020). A **detecção de emoções** vai além da polaridade binária e classifica o conteúdo emocional em categorias como alegria, medo, raiva e tristeza, conforme modelos psicológicos de afeto (Bollen; Mao; Zeng, 2011); essa dimensão foi explorada de forma pioneira por Bollen; Mao; Zeng (2011) ao decompor o humor coletivo do Twitter em seis dimensões do GPOMS (*Google-Profile of Mood States*) e correlacioná-las ao DJIA.

No que diz respeito aos níveis de análise, a literatura distingue entre a análise em nível de **documento** — em que uma publicação ou notícia inteira é classificada com uma única polaridade — e a análise em nível de **sentença** — em que cada sentença é classificada individualmente, permitindo capturar a coexistência de sentimentos contraditórios num mesmo texto (Kearney; Liu, 2014). Para publicações curtas como *tweets*, os dois níveis tendem a coincidir, dada a natureza unitária e concisa de cada publicação (Bollen; Mao; Zeng, 2011; Ranco *et al.*, 2015). Este trabalho opera predominantemente no nível de documento/publicação, classificando cada *tweet* individualmente como positivo, negativo

ou neutro.

2.4.2 Abordagens Metodológicas

As abordagens para realização de AS podem ser organizadas em três grandes famílias, cada uma com características, vantagens e limitações distintas (Kearney; Liu, 2014; Liu; Zheng; Song, 2020; Lucas; Peixoto, 2025).

A **abordagem baseada em léxicos** classifica o sentimento de um texto computando a soma (ou média ponderada) das pontuações de sentimento das palavras individuais que o compõem, conforme um dicionário pré-compilado que associa cada palavra a um valor de polaridade (Loughran; McDonald, 2011; Sousa *et al.*, 2025). As principais vantagens dessa abordagem são a interpretabilidade, a ausência de necessidade de dados rotulados para treinamento e a facilidade de incorporação de conhecimento especializado de domínio (Lucas; Peixoto, 2025). Suas limitações são igualmente conhecidas: léxicos de propósito geral falham em capturar o significado específico do vocabulário financeiro, conforme demonstrado por Loughran; McDonald (2011); a abordagem é sensível a fenômenos de negação (e.g., "*não subiu*"), ironia e sarcasmo; e não captura dependências contextuais entre palavras distantes no texto (Liu; Zheng; Song, 2020). No contexto brasileiro, Lucas; Peixoto (2025) demonstraram que os léxicos VADER e HIV conseguem explicar, respectivamente, 28,8% e 18,4% da variância do Ibovespa quando aplicados a notícias financeiras em português — resultado significativo, mas limitado pela inadequação dos léxicos ao vocabulário do mercado brasileiro.

A **abordagem baseada em aprendizado de máquina** treina modelos estatísticos ou neurais sobre conjuntos de textos rotulados para aprender, a partir dos dados, os padrões linguísticos associados a cada classe de sentimento (Liu; Zheng; Song, 2020). Métodos tradicionais como Naïve Bayes, Máquinas de Vetores de Suporte (SVM) e árvores de decisão operam sobre representações esparsas do texto (*bag-of-words*, TF-IDF) e alcançam bom desempenho em domínios com vocabulário estável e dados rotulados suficientes (Sousa *et al.*, 2025). A principal limitação dessa família é a dependência de grandes corpora anotados, que são escassos no domínio financeiro em português (Santos; Bianchi; Costa, 2023b; Sousa *et al.*, 2025). Além disso, modelos treinados em textos de um domínio ou gênero específico generalizam com dificuldade para outros contextos.

A **abordagem baseada em modelos de linguagem profundos**, em particular os modelos *transformer* discutidos na Seção 2.3.3, representa o estado da arte atual em AS (Liu; Zheng; Song, 2020; Santos; Bianchi; Costa, 2023b). Esses modelos aprendem representações contextualizadas das palavras e sentenças durante o pré-treinamento em grandes corpora não rotulados e são depois ajustados (*fine-tuned*) para a tarefa de classificação de sentimento com um número relativamente pequeno de exemplos rotulados. A contextualização é a chave para superar as limitações das abordagens anteriores: o

significado de cada palavra é função de todo o contexto em que ocorre, permitindo que o modelo capture negações, ambiguidades e nuances semânticas que os léxicos e os modelos *bag-of-words* não conseguem representar (Jurafsky; Martin, 2026; Devlin *et al.*, 2019). A **abordagem híbrida**, por fim, combina elementos léxicos com modelos de aprendizado, aproveitando a especificidade dos dicionários especializados para enriquecer as representações aprendidas pelo modelo neural (Kearney; Liu, 2014; Sousa *et al.*, 2025).

2.4.3 Análise de Sentimento no Domínio Financeiro em Português

A aplicação da AS ao domínio financeiro em língua portuguesa apresenta desafios e oportunidades específicos que justificam o esforço de especialização de recursos e modelos. Como discutido na Seção 2.2.3, a transferência direta de ferramentas desenvolvidas para o inglês financeiro produz resultados sistematicamente inferiores ao potencial da área (Loughran; McDonald, 2011; Santos; Bianchi; Costa, 2023b). O vocabulário do mercado financeiro brasileiro é rico em termos técnicos, siglas de índices e ativos (Ibovespa, IPCA, Selic, PETR4), referências institucionais (B3, CVM, Banco Central) e expressões idiomáticas que não possuem correspondentes diretos em léxicos ou corpora em inglês (Sousa *et al.*, 2025; Falcão, 2020).

Os primeiros trabalhos aplicados ao mercado brasileiro utilizaram principalmente abordagens léxicas e modelos de aprendizado de máquina raso. Falcão (2020) analisou notícias do Valor Econômico e da Folha de São Paulo entre 2013 e 2019, correlacionando o sentimento extraído com o comportamento do Ibovespa e de cinco ações de diferentes setores, e constatou que os sentimentos tendem a ser neutros na maioria dos dias, seguindo tendências pessimistas em períodos de maior incerteza econômica. Galdi; Gonçalves (2018) investigaram a relação entre pessimismo e incerteza das notícias e o comportamento dos investidores brasileiros, evidenciando que o conteúdo informacional da mídia influencia a visão dos investidores especialmente em momentos de maior turbulência do mercado.

A consolidação do paradigma *transformer* no PLN abriu novas perspectivas para o domínio financeiro em português. O modelo FinBERT-PT-BR (Santos; Bianchi; Costa, 2023b), desenvolvido por Santos; Bianchi; Costa (2023b) a partir do ajuste fino do BERTimbau (Souza; Nogueira; Lotufo, 2020) sobre 1,4 milhão de sentenças de notícias financeiras em português, estabeleceu um novo estado da arte para a tarefa de classificação de sentimento no domínio. O modelo é publicamente disponível e foi avaliado em um conjunto de 500 sentenças rotuladas de notícias financeiras, superando modelos multilíngues e léxicos especializados nas métricas de acurácia, F1-Score, precisão e recall (Santos; Bianchi; Costa, 2023b). Iniciativas paralelas de construção de léxicos especializados para o português financeiro, como a proposta de expansão automática por Word2Vec e PMI de Sousa *et al.* (2025), alcançaram F1-Score de 80% em *tweets* quando combinadas com classificadores SVM, evidenciando o potencial das abordagens híbridas para complementar os modelos

neurais.

No presente trabalho, adota-se o modelo FinBERT-PT-BR como ferramenta central para a extração de polaridade das publicações do X/Twitter relacionadas ao mercado financeiro brasileiro. Essa escolha é motivada por três fatores: (i) a especialização do modelo no vocabulário financeiro em português do Brasil; (ii) seu desempenho superior ao estado da arte anterior nas tarefas de classificação de sentimento financeiro; e (iii) sua disponibilidade pública, que garante a reprodutibilidade da metodologia proposta. A aplicação do modelo ao corpus de *tweets* coletados, bem como a análise dos índices de sentimento resultantes, é detalhada no Capítulo 3.

2.5 Trabalhos Relacionados

Esta seção apresenta os principais trabalhos que situam o presente estudo na trajetória da pesquisa em análise de sentimento aplicada a mercados financeiros. A revisão está organizada em dois grupos: trabalhos internacionais que estabeleceram os fundamentos metodológicos da área e trabalhos nacionais que aplicaram técnicas de análise de sentimento ao mercado financeiro brasileiro, evidenciando a lacuna que este trabalho busca contribuir para preencher.

2.5.1 Trabalhos Internacionais

O estudo pioneiro de Antweiler; Frank (2004) foi o primeiro a examinar sistematicamente o conteúdo informacional de textos gerados por usuários em plataformas digitais para análise de mercado. Os autores analisaram aproximadamente 1,5 milhão de mensagens publicadas nos fóruns Yahoo Finance e Raging Bull entre 1999 e 2001, relativas a 45 empresas do Dow Jones Industrial Average e do Dow Jones Internet Index. Utilizando dicionários léxicos para classificar as mensagens em positivas, negativas e neutras, identificaram que o volume de mensagens era preditivo da volatilidade do mercado e que o conteúdo apresentava relação estatisticamente significativa com retornos subsequentes. Embora os efeitos sobre retornos fossem economicamente modestos, o trabalho estabeleceu o precedente metodológico central para a área: textos gerados por usuários carregam conteúdo informacional com implicações para a dinâmica dos preços de ativos.

Tetlock (2007) ampliou essa perspectiva ao analisar o conteúdo da coluna "Abreast of the Market" do Wall Street Journal entre 1984 e 1999. Utilizando o dicionário Harvard General Inquirer para extrair o componente de pessimismo do texto jornalístico, o autor demonstrou que altos níveis de pessimismo na mídia antecipavam quedas nos retornos do mercado, enquanto um pessimismo anormalmente alto ou baixo era seguido de reversão à média. O trabalho foi fundamental por conectar explicitamente o conteúdo qualitativo da mídia financeira à Hipótese do Mercado Eficiente, sugerindo que o sentimento expresso em

texto pode conter informação que os preços demoram a incorporar plenamente (Tetlock, 2007; Fama, 1970).

O trabalho de Bollen; Mao; Zeng (2011) representou o marco mais influente para o campo ao deslocar o foco dos textos jornalísticos para as redes sociais. Analisando cerca de 9,7 milhões de *tweets* publicados entre abril e dezembro de 2008, os autores mensuraram o humor coletivo por meio de duas ferramentas — OpinionFinder e GPOMS — e demonstraram, por análise de causalidade de Granger, que a dimensão "Calma" do GPOMS apresentava causalidade preditiva sobre os valores de fechamento do DJIA com defasagem de dois a seis dias, alcançando acurácia de 87,6% na previsão de movimentos diários de alta e baixa. A sofisticação metodológica do trabalho — combinando análise de sentimento multidimensional, testes de causalidade e redes neurais *fuzzy* — e a robustez de seus resultados tornaram-no a referência central da área, com mais de dez mil citações na literatura (Bollen; Mao; Zeng, 2011).

Ranco *et al.* (2015) estenderam essa linha de pesquisa ao examinar a relação entre sentimento no Twitter e retornos das 30 ações componentes do DJIA, em vez do índice agregado. Os autores identificaram que o impacto do sentimento é especialmente pronunciado nos dias que antecedem e sucedem eventos corporativos relevantes — como divulgação de resultados trimestrais e anúncios de fusões —, e que a correlação entre sentimento e retornos é assimétrica: eventos de sentimento negativo tendem a ter impacto mais imediato e acentuado do que eventos positivos. Kearney; Liu (2014), por fim, forneceram a síntese mais abrangente do campo até então, revisando mais de cem estudos sobre análise de sentimento em finanças e organizando-os em torno das dimensões de fonte de dados, método de extração de sentimento e variável financeira de interesse. Os autores concluem que as fontes não convencionais de dados textuais — incluindo mídias sociais — constituem um complemento informacionalmente rico às fontes tradicionais de dados financeiros, e que a escolha do método de análise deve ser guiada pela especificidade do domínio e da língua em questão (Kearney; Liu, 2014).

2.5.2 Trabalhos Nacionais

No contexto brasileiro, a pesquisa em análise de sentimento aplicada ao mercado financeiro é mais recente e ainda escassa, especialmente no que diz respeito ao uso de publicações em redes sociais como fonte de dados. Os trabalhos existentes concentram-se predominantemente na análise de notícias em português, com resultados que evidenciam tanto o potencial da abordagem quanto a lacuna de recursos linguísticos especializados.

Galdi; Gonçalves (2018) investigaram a relação entre o pessimismo e a incerteza das notícias financeiras e o comportamento dos investidores no Brasil. Utilizando o índice de legibilidade de Gunning Fog e um dicionário léxico adaptado ao português, os autores analisaram notícias relacionadas a empresas listadas na B3 e encontraram evidências de que

o conteúdo informacional da mídia influencia as decisões dos investidores, especialmente em períodos de maior turbulência econômica. O trabalho foi pioneiro ao aplicar técnicas de análise de conteúdo textual ao mercado acionário brasileiro e ao demonstrar que variáveis qualitativas extraídas de notícias possuem poder explicativo sobre o comportamento dos preços, complementando indicadores quantitativos tradicionais (Galdi; Gonçalves, 2018).

Falcão (2020) realizou uma análise abrangente do efeito do sentimento textual de notícias financeiras sobre os preços no mercado acionário brasileiro. O trabalho analisou textos do Valor Econômico e da Folha de São Paulo entre janeiro de 2013 e agosto de 2019 — totalizando 1.470 observações diárias — e correlacionou o sentimento extraído com os valores diários do Ibovespa e de cinco ações de setores distintos (Ambev, Itaú, Magazine Luiza, Petrobras e Vale). Os léxicos LIWC, SentiLex e OpLexicon foram empregados para extração de sentimento, e os resultados indicaram que os sentimentos tendem a ser neutros na maioria dos dias, seguindo tendências pessimistas em períodos de incerteza econômica elevada. O estudo concluiu que o conteúdo dos jornais brasileiros influencia a visão dos investidores especialmente em momentos de maior incerteza, fornecendo evidências de que o corpus de notícias é uma fonte de informação relevante para a tomada de decisão no mercado brasileiro (Falcão, 2020).

Santos; Bianchi; Costa (2023b) introduziram o avanço mais significativo para o campo ao proporem o **FinBERT-PT-BR**, modelo BERT especializado para o domínio financeiro em português. O modelo foi desenvolvido em duas etapas: pré-treinamento sobre 1,4 milhão de sentenças de notícias financeiras coletadas do Valor Econômico, Exame e InfoMoney (2006–2022) a partir do BERTimbau (Souza; Nogueira; Lotufo, 2020); e ajuste fino para classificação de sentimento sobre 500 sentenças anotadas, gerando o modelo SentFinBERT-PT-BR. Os autores demonstraram que o modelo supera abordagens léxicas e modelos multilíngues em métricas de acurácia, precisão, recall e F1-Score, e que o índice de sentimento por ele gerado captura eventos macroeconômicos relevantes da história recente do Brasil — como a Operação Lava Jato (2014), o *impeachment* de Dilma Rousseff (2016), o "Joesley Day" (2017) e a pandemia de COVID-19 (2020) — com alta aderência ao sentimento prevalente em cada período (Santos; Bianchi; Costa, 2023b).

Mais recentemente, três trabalhos buscaram avançar a agenda de pesquisa no mercado financeiro brasileiro por caminhos metodológicos complementares. Sousa *et al.* (2025) propuseram uma abordagem híbrida de expansão automática de léxicos especializados para o Mercado Financeiro Brasileiro (MFB), combinando um léxico semente em português com técnicas de Word2Vec, busca por sinônimos/antônimos e Informação Mútua Pontual (PMI). O léxico resultante alcançou F1-Score de 71,5% na classificação de *tweets* e de 68,4% em notícias do MFB, valores que sobem para 80% quando combinados com um classificador SVM, demonstrando o potencial das abordagens híbridas para o domínio financeiro em português (Sousa *et al.*, 2025). Lucas; Peixoto (2025), por sua

vez, avaliaram sistematicamente a abordagem léxica na análise de sentimento de notícias do mercado financeiro coletadas via Google News API, aplicando os léxicos VADER e HIV ao Ibovespa. Os resultados mostraram que esses léxicos, originalmente desenvolvidos para o inglês e aplicados após tradução automática dos títulos, explicam respectivamente 28,8% e 18,4% da variância do índice — resultado expressivo dado o caráter genérico dos dicionários empregados, mas que reforça a necessidade de recursos especializados para o português financeiro (Lucas; Peixoto, 2025). Silva *et al.* (2025) investigaram a extração de sentimento de notícias do Yahoo Finance entre 2020 e 2023, utilizando VADER e TextBlob para correlacionar o sentimento com variações do S&P 500. Os autores observaram que, em determinados períodos — como o início de 2021 —, o aumento de notícias positivas coincidiu com a recuperação do mercado, mas concluíram que a relação entre sentimento e desempenho do mercado não é linear, sugerindo a influência de fatores macroeconômicos e geopolíticos que não são capturados pela análise de sentimento isolada (Silva *et al.*, 2025).

2.5.3 Síntese Comparativa e Posicionamento do Presente Trabalho

O Quadro 1 sintetiza os principais trabalhos relacionados, organizados pelas dimensões de fonte de dados, método de análise de sentimento, mercado-alvo e principal resultado.

A análise comparativa evidencia que o presente trabalho ocupa uma posição específica e ainda pouco explorada na interseção de três dimensões. Em primeiro lugar, no que diz respeito à **fonte de dados**: embora Twitter/X tenha sido amplamente utilizado em estudos internacionais (Bollen; Mao; Zeng, 2011; Ranco *et al.*, 2015), os trabalhos nacionais concentram-se predominantemente em notícias de portais jornalísticos, com poucos estudos explorando sistematicamente publicações do X/Twitter em português financeiro (Sousa *et al.*, 2025). Em segundo lugar, no que concerne ao **método de análise**: enquanto os trabalhos brasileiros mais recentes utilizam majoritariamente abordagens léxicas (Lucas; Peixoto, 2025; Sousa *et al.*, 2025) ou redes neurais genéricas (Silva *et al.*, 2025), este trabalho adota o FinBERT-PT-BR — o modelo de estado da arte especificamente treinado para o domínio financeiro em português — o que representa um avanço metodológico em relação às abordagens anteriores. Em terceiro lugar, em relação ao **mercado-alvo**: a aplicação ao contexto específico da B3, com foco nos índices do mercado acionário brasileiro, responde à demanda por estudos que considerem as particularidades institucionais, linguísticas e econômicas do Brasil, distinguindo-se dos trabalhos que utilizam o S&P 500 ou o DJIA como referência (Silva *et al.*, 2025; Bollen; Mao; Zeng, 2011).

A contribuição principal deste trabalho, portanto, consiste em integrar uma fonte de dados de alta temporalidade (X/Twitter em tempo real) com o método de análise de sentimento de maior desempenho disponível para o português financeiro (FinBERT-PT-BR), aplicando essa combinação ao mercado acionário brasileiro, lacuna ainda não

Tabela 1 – Síntese dos trabalhos relacionados

Trabalho	**Fonte de Dados**	**Método**	**Mercado**	**Principal Resultado**
Antweiler & Frank (2004)	Fóruns Yahoo Finance / Raging Bull	Léxico (Harvard GI)	EUA (DJIA)	Volume de msg. prevê volatilidade
Tetlock (2007)	Wall Street Journal	Léxico (Harvard GI)	EUA (S&P 500)	Pessimismo na mídia antecipa quedas
Bollen et al. (2011)	Twitter	OpinionFinder / GPOMS	EUA (DJIA)	Humor coletivo prevê DJIA (87,6%)
Ranco et al. (2015)	Twitter	SVM / léxico	EUA (DJIA 30)	Sentimento impacta mais em eventos corporativos
Galdi & Gonçalves (2018)	Notícias (B3)	Léxico adaptado ao PT	Brasil (B3)	Pessimismo em notícias afeta investidores em períodos de incerteza
Falcão (2020)	Valor Econômico / Folha SP	LIWC / SentiLex / OpLexicon	Brasil (Ibovespa + 5 ações)	Sentimento neutro na maioria dos dias; pessimismo em crises
Santos et al. (2023)	Notícias (Valor / Exame / InfoMoney)	FinBERT-PT-BR (BERT)	Brasil (mercado geral)	Estado da arte em AS financeiro em PT-BR
Sousa et al. (2025)	Tweets + Notícias (MFB)	Léxico híbrido (Word2Vec + PMI + SVM)	Brasil (MFB)	F1-Score 80% em tweets com léxico+SVM
Lucas & Peixoto (2025)	Notícias (Google News)	VADER / HIV (léxicos)	Brasil (Ibovespa)	Léxicos genéricos explicam 28,8% da variância do Ibovespa
Silva et al. (2025)	Yahoo Finance	VADER / TextBlob	EUA (S&P 500)	Relação sentimento–mercado não é linear
Presente trabalho	**X/Twitter**	**FinBERT-PT-BR**	**Brasil (B3)**	**AS de tweets financeiros em PT-BR com modelo especializado**

Fonte: Elaborado pelo autor.

explorada na literatura nacional revisada.

3 METODOLOGIA

4 AVALIAÇÃO EXPERIMENTAL

5 CONCLUSÕES

REFERÊNCIAS

ANTWEILER, W.; FRANK, M. Z. Is all that talk just noise? The information content of internet stock message boards. **The Journal of Finance**, v. 59, n. 3, p. 1259–1294, 2004. Acesso aberto (PDF do autor): https://wernerantweiler.ca/public/noise-a.pdf. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=282320.

ARACI, D. FinBERT: Financial sentiment analysis with pre-trained language models. **arXiv preprint**, 2019. Disponível em: https://arxiv.org/abs/1908.10063.

BAKER, M.; WURGLER, J. Investor sentiment in the stock market. **Journal of Economic Perspectives**, v. 21, n. 2, p. 129–151, 2007. Acesso aberto (PDF NYU): https://pages.stern.nyu.edu/~jwurgler/papers/wurgler_baker_investor_sentiment.pdf. AEA: https://www.aeaweb.org/articles?id=10.1257/jep.21.2.129.

BOLLEN, J.; MAO, H.; ZENG, X. Twitter mood predicts the stock market. **Journal of Computational Science**, v. 2, n. 1, p. 1–8, 2011.

CASELI, H. d. M.; NUNES, M. d. G. V.; PAGANO, A. O que é pln? *In*: CASELI, H. M.; NUNES, M. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. BPLN, 2024. cap. 1. ISBN 978-65-01-20581-6. Disponível em: https://brasileiraspln.com/livro-pln/3a-edicao/parte-introducao/cap-introducao/cap-introducao.html.

CHEN, M.; MAO, S.; LIU, Y. Big data: A survey. **Mobile Networks and Applications**, v. 19, n. 2, p. 171–209, 2014. Acesso aberto (ResearchGate): https://www.researchgate.net/publication/259529914_Big_Data_A_Survey. Springer: https://link.springer.com/article/10.1007/s11036-013-0489-0.

CLARO, D. B. *et al.* Extração de informação. *In*: CASELI, H. M.; NUNES, M. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. BPLN, 2024. cap. 22. ISBN 978-65-01-20581-6. Disponível em: https://brasileiraspln.com/livro-pln/3a-edicao/parte-aplicacoes/cap-ie/cap-ie.html.

DEVLIN, J. *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding. *In*: **Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)**. Association for Computational Linguistics, 2019. p. 4171–4186. Disponível em: https://arxiv.org/abs/1810.04805.

FALCÃO, M. C. d. S. **Análise de Sentimento de Notícias do Mercado Financeiro**. 2020. Monografia (Projeto de Graduação) — Escola Politécnica, Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2020. Orientador: Prof. Heraldo Luís Silveira de Almeida, D.Sc.

FAMA, E. F. Efficient capital markets: A review of theory and empirical work. **The Journal of Finance**, v. 25, n. 2, p. 383–417, 1970. Disponível em: https://www.jstor.org/stable/2325486.

FAMA, E. F. Efficient capital markets: II. **The Journal of Finance**, v. 46, n. 5, p. 1575–1617, 1991. Acesso aberto (PDF): https://www.bu.edu/econ/files/2011/01/Fama2.pdf. Wiley: https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1540-6261.1991.tb04636.x.

FREITAS, C. Dataset e corpus. *In*: CASELI, H. M.; NUNES, M. G. V. (ed.). **Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português**. 3. ed. BPLN, 2024. cap. 13. ISBN 978-65-01-20581-6. Disponível em: https://brasileiraspln.com/livro-pln/3a-edicao/parte-dados-avaliacao/cap-dataset-corpus/cap-dataset-corpus.html.

GALDI, F. C.; GONÇALVES, A. M. Pessimismo e incerteza das notÍcias e o comportamento dos investidores no brasil. **Revista de Administração de Empresas**, Fundação Getulio Vargas, Escola de Administração de Empresas de S.Paulo, v. 58, n. 2, p. 130–148, Mar 2018. ISSN 0034-7590. Disponível em: https://doi.org/10.1590/S0034-759020180203.

GALDI, F. C.; GONçALVES, A. M. Pessimismo e incerteza das notícias e o comportamento dos investidores no brasil. **Revista de Administração de Empresas**, Fundação Getulio Vargas, Escola de Administração de Empresas de S.Paulo, v. 58, n. 2, p. 130–148, mar. 2018. ISSN 0034-7590. Disponível em: https://doi.org/10.1590/S0034-759020180203.

GROSSMAN, S. J.; STIGLITZ, J. E. On the impossibility of informationally efficient markets. **The American Economic Review**, v. 70, n. 3, p. 393–408, 1980. JSTOR: https://www.jstor.org/stable/1805228. Acesso aberto (PDF): https://www.jstor.org/stable/1805228.

JR., N. C. A. C. Overreaction in the Brazilian stock market. **Journal of Banking & Finance**, v. 18, n. 4, p. 633–642, 1994. ScienceDirect: https://www.sciencedirect.com/science/article/abs/pii/0378426694000115.

JURAFSKY, D.; MARTIN, J. H. **Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models**. 3rd. ed. [*S.l.: s.n.*], 2026. Online manuscript released January 6, 2026. Disponível em: https://web.stanford.edu/~jurafsky/slp3/.

KEARNEY, C.; LIU, S. Textual sentiment in finance: A survey of methods and models. **International Review of Financial Analysis**, v. 33, p. 171–185, 2014. Acesso aberto (Open Access UCD): https://researchrepository.ucd.ie/handle/10197/8213. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=2213801. ScienceDirect: https://www.sciencedirect.com/science/article/abs/pii/S1057521914000295.

LANEY, D. **3D Data Management: Controlling Data Volume, Velocity, and Variety**. [*S.l.*], 2001. Documento fundacional do conceito dos “3 Vs” do Big Data. Acesso aberto (PDF Gartner): http://blogs.gartner.com/doug-laney/files/2012/01/ad949-3D-Data-Management-Controlling-Data-Volume-Velocity-and-Variety.pdf.

LIU, X.; ZHENG, X.; SONG, X. A survey of text classification: From shallow to deep learning. **arXiv preprint**, 2020. Acesso aberto (arXiv): https://arxiv.org/abs/2008.00364.

LO, A. W. The adaptive markets hypothesis: Market efficiency from an evolutionary perspective. **The Journal of Portfolio Management**, v. 30, n. 5, p. 15–29, 2004. Disponível em: https://web.mit.edu/Alo/www/Papers/JPM2004_Pub.pdf.

LO, A. W. Reconciling efficient markets with behavioral finance: The adaptive markets hypothesis. **Journal of Investment Consulting**, v. 7, n. 2, p. 21–44, 2005. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=728864.

LOUGHRAN, T.; MCDONALD, B. When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. **The Journal of Finance**, v. 66, n. 1, p. 35–65, 2011. Acesso aberto (PDF do autor): https://www3.nd.edu/~mcdonald/Word_Lists_files/Publications/Loughran_McDonald_2011_JF.pdf. Wiley: https://onlinelibrary.wiley.com/doi/10.1111/j.1540-6261.2010.01625.x.

LUCAS, I. d. C.; PEIXOTO, N. G. M. Análise de sentimento com abordagem léxica: Aplicação em notícias do mercado financeiro. **Trabalho de Conclusão de Curso — Bacharelado em Engenharia de Software, PUC Minas**, 2025. Orientador: Rodrigo Baroni de Carvalho. Belo Horizonte, 30 de junho de 2025.

MAO, H.; COUNTS, S.; BOLLEN, J. Predicting financial markets: Comparing survey, news, Twitter and search engine data. **arXiv preprint**, 2011. Acesso aberto (arXiv): https://arxiv.org/abs/1112.1051.

MAYER-SCHÖNBERGER, V.; CUKIER, K. **Big Data: A Revolution That Will Transform How We Live, Work, and Think**. Boston, MA: Houghton Mifflin Harcourt, 2013. ACM Digital Library: https://dl.acm.org/doi/10.5555/2588165. Google Books (prévia): https://books.google.com/books?id=uy4lh-WEhhIC. ISBN 9780544002692.

RANCO, G. *et al.* The effects of Twitter sentiment on stock price returns. **PLOS ONE**, v. 10, n. 9, p. e0138441, 2015. Acesso aberto (PLOS ONE): https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0138441. arXiv: https://arxiv.org/abs/1506.02431.

SANTOS, L. L.; BIANCHI, R. A. C.; COSTA, A. H. R. Finbert-pt-br: Análise de sentimentos de textos em português do mercado financeiro. *In*: **Anais do Brazilian Workshop on Artificial Intelligence in Finance (BWAIF)**. Porto Alegre, RS, Brasil: SBC, 2023. Disponível em: https://sol.sbc.org.br/index.php/bwaif/article/view/24960.

SANTOS, L. L.; BIANCHI, R. A. C.; COSTA, A. H. R. FinBERT-PT-BR: Análise de sentimentos de textos em português do mercado financeiro. *In*: **Anais do Brazilian Workshop on Artificial Intelligence in Finance (BWAIF)**. Porto Alegre, RS, Brasil: SBC, 2023. Disponível em: https://sol.sbc.org.br/index.php/bwaif/article/view/24960.

SILVA, F. S. d. *et al.* Processo de extração de sentimento no mercado financeiro. **Boletim de Conjuntura (BOCA)**, v. 21, n. 62, p. 318–338, 2025. ISSN: 2675-1488. Acesso aberto: https://doi.org/10.5281/zenodo.15092801.

SOUSA, T. M. d. *et al.* Expansão automática de léxico para análise de sentimentos de textos no domínio do mercado financeiro brasileiro. **Revista de Educação, Ciência e Tecnologia do IFG**, v. 10, n. Edição Especial 1, 2025. Submetido: 30/05/2024. Aprovado: 21/03/2025.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: Pretrained BERT models for brazilian portuguese. *In*: **9th Brazilian Conference on Intelligent Systems (BRACIS)**. Springer, 2020. p. 403–417. Disponível em: https://arxiv.org/abs/2006.02960.

SPRENGER, T. O. *et al.* Tweets and trades: The information content of stock microblogs. **European Financial Management**, v. 20, n. 5, p. 926–957, 2014. Wiley: https://onlinelibrary.wiley.com/doi/abs/10.1111/j.1468-036X.2013.12007.x. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=1702854.

TETLOCK, P. C. Giving content to investor sentiment: The role of media in the stock market. **The Journal of Finance**, v. 62, n. 3, p. 1139–1168, 2007. Acesso aberto (PDF Columbia): https://business.columbia.edu/sites/default/files-efs/pubfiles/3097/Tetlock_Media_Sentiment_JF.pdf. SSRN: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=685145.

VASWANI, A. *et al.* Attention is all you need. *In*: **Advances in Neural Information Processing Systems (NeurIPS)**. [*S.l.: s.n.*], 2017. v. 30. Disponível em: https://arxiv.org/abs/1706.03762.

YOSHINAGA, C. E.; CASTRO, F. H. F. d. The relationship between market sentiment index and stock rates of return: A panel data analysis. **Brazilian Administration Review**, v. 9, n. 2, p. 189–210, 2012. Acesso aberto (SciELO): https://www.scielo.br/j/bar/a/MFZPpHF8fH9PfjQ3h4QLWFs/.