UNIVERSIDADE DE SÃO PAULO
Instituto de Ciências Matemáticas e de Computação

Análise Preditiva de Ações Baseada em Notícias

Antonio Lopes Jr

Monografia - MBA em Inteligência Artificial e Big Data

ICMC USP
SÃO CARLOS

SERVIÇO DE PÓS-GRADUAÇÃO DO ICMC-USP

Data de Depósito:

Assinatura: _____

Antonio Lopes Jr

Análise Preditiva de Ações Baseada em Notícias

Monografia apresentada ao Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, como parte dos requisitos para obtenção do título de Especialista em Inteligência Artificial e Big Data.

Área de concentração: Inteligência Artificial

Orientadora: Prof. Dr. Fernando Pereira dos Santos

Versão original

São Carlos

2026

AUTORIZO A REPRODUÇÃO E DIVULGAÇÃO TOTAL OU PARCIAL DESTE TRABALHO, POR QUALQUER MEIO CONVENCIONAL OU ELETRÔNICO PARA FINS DE ESTUDO E PESQUISA, DESDE QUE CITADA A FONTE.

Ficha catalográfica elaborada pela Biblioteca Prof. Achille Bassi, ICMC/USP, com os dados fornecidos pelo(a) autor(a)

S856m

Lopes Jr, Antonio
Análise Preditiva de Ações Baseada em Notícias / Antonio Lopes Jr ; orientador Fernando Pereira dos Santos. – São Carlos, 2026.
33 p. : il. (algumas color.) ; 30 cm.

Monografia (MBA em Inteligência Artificial e Big Data) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, 2026.

1. LaTeX. 2. abnTeX. 3. Classe USPSC. 4. Editoração de texto. 5. Normalização da documentação. 6. Tese. 7. Dissertação. 8. Documentos (elaboração). 9. Documentos eletrônicos. I. Santos, Fernando Pereira, orient. II. Título.

Antonio Lopes Jr

Predictive Analysis of Stocks Based on News

Monograph presented to the Departamento de Ciências de Computação do Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo - ICMC/USP, as part of the requirements for obtaining the title of Specialist in Artificial Intelligence and Big Data.

Concentration area: Artificial Intelligence

Advisor: Prof. Dr. Fernando Pereira dos Santos

Original version

São Carlos

2026

RESUMO

LOPES JR, A. **Análise Preditiva de Ações Baseada em Notícias**. 2026. 33 p. Monografia (MBA em Inteligência Artificial e Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

Apresentar, em resumo, a contextualização, motivação, lacunas, proposta, resultados, direções e conclusões. (1 parágrafo (+- 500 palavras)).

O resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. (. . .) Salientamos que algumas Unidades exigem o titulo dos trabalhos acadêmicos em inglês, tornando necessário a inclusão das referências nos resumos e abstracts, o que foi adotado no **Modelo para TCC em LaTeX utilizando a classe USPSC** e no **Modelo para teses e dissertações em LaTeX utilizando a classe USPSC**. As palavras-chave devem figurar logo abaixo do resumo, antecedidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto nbr6028.

Palavras-chave: LaTeX. Classe USPSC. Tese. Dissertação. Trabalho de conclusão de curso (TCC). Relatório.

ABSTRACT

LOPES JR, A. **Predictive Analysis of Stocks Based on News**. 2026. 33 p. Monograph (MBA in Artificial Intelligence and Big Data) - Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2026.

This is the english abstract.

Keywords: LaTeX. USPSC class. Thesis. Dissertation. Conclusion course paper. Report.

LISTA DE FIGURAS

LISTA DE TABELAS

LISTA DE QUADROS

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
abnTeX	ABsurdas Normas para TeX
IBGE	Instituto Brasileiro de Geografia e Estatística
LaTeX	Lamport TeX
USP	Universidade de São Paulo
USPSC	Campus USP de São Carlos

SUMÁRIO

1 INTRODUÇÃO . . . 21
1.1 Problema . . . 21
1.2 Justificativa . . . 22
1.3 Objetivos . . . 22
1.3.1 Objetivo Geral . . . 22
1.3.2 Objetivos Específicos . . . 23
1.4 Delimitação do Escopo . . . 23
1.5 Estrutura do Trabalho . . . 23

2 FUNDAMENTAÇÃO TEÓRICA . . . 25
2.1 Mercado Financeiro Brasileiro . . . 25
2.1.1 Índices de Ações da B3 . . . 25
2.1.1.1 Ibovespa (IBOV) . . . 25
2.1.1.2 Índice Dividendos (IDIV) . . . 25
2.1.1.3 Índice Small Caps (SMLL) . . . 25

3 METODOLOGIA . . . 27

4 AVALIAÇÃO EXPERIMENTAL . . . 29

5 CONCLUSÕES . . . 31

REFERÊNCIAS . . . 33

1 INTRODUÇÃO

O mercado financeiro é intrinsecamente volátil, impulsionado não apenas por fundamentos econômicos, mas também por eventos políticos, macroeconômicos, regulatórios e pela percepção coletiva (sentimento) disseminada em dados não estruturados massivos, como notícias de imprensa e mídias sociais.

Embora a relação entre divulgação de resultados corporativos, indicadores macroeconômicos e movimentação de preços seja amplamente documentada, a influência do sentimento público capturado em notícias e mídias sociais sobre o comportamento dos ativos permanece menos compreendida e quantificada. O volume massivo e a alta velocidade (*volume* e *velocity*) de geração desses dados textuais não estruturados configuram um desafio típico de *Big Data*, excedendo a capacidade de análise humana em tempo real e criando assimetrias informacionais no mercado.

Estudos empíricos demonstram que termos com conotação de incerteza nas edições diárias do jornal Valor Econômico apresentam associação negativa estatisticamente significante com o retorno diário do Ibovespa, enquanto palavras com tom negativo correlacionam-se positivamente com o aumento da volatilidade do índice (GALDI; GONÇALVES, 2018), evidenciando o impacto quantificável do sentimento noticioso sobre a dinâmica de preços no mercado brasileiro.

1.1 Problema

Nesse contexto, emerge a seguinte questão de pesquisa: como estruturar e quantificar, em escala, a polaridade e o conteúdo semântico de publicações financeiras no X/Twitter para caracterizar o sentimento do mercado brasileiro?

Estudos internacionais já demonstraram que o sentimento expresso em mídias sociais mantém relação mensurável com o comportamento do mercado financeiro - Bollen, Mao e Zeng (2011), por exemplo, identificaram associação estatisticamente significante entre o humor coletivo expresso no Twitter e as variações do mercado de ações norte-americano. No entanto, análises robustas e validadas dessa relação para o mercado brasileiro ainda são escassas. As particularidades linguísticas do português brasileiro, a estrutura diferenciada do mercado de capitais nacional e a limitada disponibilidade de datasets rotulados de qualidade representam desafios específicos que dificultam a transferência direta de soluções desenvolvidas para outros contextos (Santos; Bianchi; Costa, 2023).

A literatura nacional acerca do sentimento do investidor no mercado brasileiro permanece incipiente (GALDI; GONÇALVES, 2018), com poucos trabalhos dedicados à construção de modelos de PLN específicos para o domínio financeiro em português. Iniciati-

vas recentes, como o desenvolvimento do FinBERT-PT-BR (Santos; Bianchi; Costa, 2023), representam avanços importantes ao treinar modelos baseados na arquitetura BERT com 1,4 milhão de textos financeiros em português, porém ainda enfrentam limitações quanto ao tamanho das bases de dados rotuladas (apenas 503 textos anotados manualmente).

1.2 Justificativa

A literatura nacional sobre análise de sentimento aplicada ao mercado financeiro permanece incipiente (GALDI; GONÇALVES, 2018), com poucos trabalhos dedicados ao desenvolvimento de ferramentas de PLN específicas para o domínio financeiro em português brasileiro. Essa lacuna é agravada pela limitada disponibilidade de datasets rotulados de qualidade, pelas particularidades linguísticas do português e pela estrutura diferenciada do mercado de capitais nacional, fatores que dificultam a simples transposição de soluções consolidadas em outros idiomas e mercados (Santos; Bianchi; Costa, 2023).

Iniciativas recentes, como o FinBERT-PT-BR (Santos; Bianchi; Costa, 2023), representam avanços relevantes, porém ainda enfrentam restrições quanto ao tamanho das bases de dados anotadas manualmente e à ausência de pipelines reproduzíveis que integrem coleta, pré-processamento e classificação de sentimento em um fluxo estruturado. O presente trabalho busca contribuir nessa direção, ao propor e documentar um pipeline de PLN de ponta a ponta voltado ao contexto financeiro brasileiro, oferecendo à comunidade acadêmica um protocolo metodológico replicável e passível de extensão em pesquisas futuras.

Do ponto de vista prático, a capacidade de monitorar e quantificar o sentimento disseminado em publicações de veículos especializados em tempo quase real representa um recurso relevante para analistas e gestores que buscam incorporar informações não estruturadas à sua leitura de mercado. A automação desse processo por meio de técnicas de aprendizado de máquina supera a limitação humana de processar grandes volumes de dados textuais com alta velocidade, reduzindo assimetrias informacionais e ampliando a qualidade da análise qualitativa do ambiente econômico.

1.3 Objetivos

1.3.1 Objetivo Geral

Desenvolver e validar pipeline de Processamento de Linguagem Natural (PLN) para análise de sentimento de publicações financeiras no X/Twitter, caracterizando padrões temporais e semânticos do discurso financeiro brasileiro.

1.3.2 Objetivos Específicos

1. Coletar e estruturar um dataset de publicações do X/Twitter dos veículos InfoMoney e Exame, abrangendo o período de outubro de 2025 a fevereiro de 2026;
2. Realizar Análise Exploratória dos Dados (AED) e aplicar técnicas de pré-processamento para detecção e remoção de dados redundantes e valores atípicos (*outliers*);
3. Desenvolver um pipeline de pré-processamento e análise de sentimento baseado em PLN para classificação da polaridade dos textos coletados;
4. Avaliar e comparar o desempenho de diferentes abordagens de classificação de sentimento - baseadas em léxico e em modelos de linguagem pré-treinados - no domínio financeiro em português brasileiro;
5. Caracterizar descritivamente o dataset resultante, identificando a distribuição de polaridade e os padrões semânticos predominantes no discurso financeiro dos veículos analisados.

1.4 Delimitação do Escopo

Como *proxy* para captura de sentimento de mercado, serão utilizadas publicações da rede social X (anteriormente Twitter) de veículos especializados em economia e finanças: InfoMoney e Exame. O período de análise compreenderá publicações entre 10 de outubro de 2025 e 6 de fevereiro de 2026, totalizando aproximadamente quatro meses de dados.

A delimitação desse recorte temporal decorre de um conjunto de restrições metodológicas e operacionais: (i) o acesso à API do X/Twitter está condicionado a planos comerciais com janelas históricas limitadas, inviabilizando a coleta retroativa de grandes volumes de dados sem custos elevados; e (ii) o custo de acesso a planos de API com maior capacidade de recuperação histórica representa uma barreira concreta para pesquisas acadêmicas sem financiamento dedicado. Reconhece-se que esse recorte constitui uma limitação do estudo, cujos impactos serão discutidos no Capítulo 5.

A escolha por posts em detrimento de artigos completos fundamenta-se em aspectos metodológicos: (i) maior facilidade de extração estruturada de dados via API, dispensando técnicas complexas de *web scraping*; e (ii) formato textual conciso e objetivo, mais adequado para análise de polaridade semântica.

1.5 Estrutura do Trabalho

Este trabalho está organizado em cinco capítulos. O Capítulo 1 apresenta a contextualização do problema, a questão de pesquisa, a identificação do gap na literatura nacional, a justificativa e os objetivos geral e específicos da pesquisa.

O Capítulo 2 apresenta a revisão de literatura, abordando os fundamentos de Processamento de Linguagem Natural (PLN), as principais abordagens de análise de sentimento aplicadas ao mercado financeiro e os trabalhos relevantes desenvolvidos para o contexto brasileiro e para a língua portuguesa.

O Capítulo 3 descreve em detalhes a metodologia proposta, incluindo: o processo de coleta de dados via API do X/Twitter; a análise exploratória e o tratamento do dataset; e o pipeline de PLN para extração de features semânticas e classificação de polaridade dos textos coletados.

O Capítulo 4 apresenta os resultados da análise de sentimento realizada, incluindo a caracterização descritiva do dataset, os padrões temporais e semânticos identificados no discurso financeiro dos veículos analisados e a discussão dos achados à luz da literatura.

Por fim, o Capítulo 5 sintetiza as principais conclusões do trabalho, discute as contribuições científicas e práticas da pesquisa, apresenta as limitações encontradas e sugere direcionamentos para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Mercado Financeiro Brasileiro

2.1.1 Índices de Ações da B3

2.1.1.1 Ibovespa (IBOV)

O Ibovespa é o principal indicador de desempenho das ações negociadas na B3 e reúne as empresas mais importantes do mercado de capitais brasileiro. Foi criado em 1968 e de lá para cá consolidou-se como referência para investidores ao redor do mundo.

Reavaliado a cada quatro meses, o índice é composto pelas ações e units de companhias listadas na B3 que correspondem a cerca de 85% do número de negócios e do volume financeiro do nosso mercado de capitais.

2.1.1.2 Índice Dividendos (IDIV)

Objetivo de muitos dos investidores, os dividendos também têm sua participação medida em índice. O objetivo do IDIV é indicar o desempenho médio dos ativos que se destacam na distribuição de remuneração aos investidores, seja sob a forma de dividendos ou juros sobre o capital próprio (JCP).

2.1.1.3 Índice Small Caps (SMLL)

O objetivo do SMLL é ser o indicador do desempenho médio de uma carteira composta por ações de empresas de menor capitalização. Ele é composto pelas ações e units que estão fora da lista do Ibovespa, que representa 85% do valor de mercado de todas as empresas na B3.

3 METODOLOGIA

4 AVALIAÇÃO EXPERIMENTAL

5 CONCLUSÕES

REFERÊNCIAS

BOLLEN, J.; MAO, H.; ZENG, X. Twitter mood predicts the stock market. **Journal of Computational Science**, v. 2, n. 1, p. 1–8, 2011.

GALDI, F. C.; GONÇALVES, A. M. Pessimismo e incerteza das notÍcias e o comportamento dos investidores no brasil. **Revista de Administração de Empresas**, Fundação Getulio Vargas, Escola de Administração de Empresas de S.Paulo, v. 58, n. 2, p. 130–148, Mar 2018. ISSN 0034-7590. Disponível em: https://doi.org/10.1590/S0034-759020180203.

SANTOS, L. L.; BIANCHI, R. A. C.; COSTA, A. H. R. Finbert-pt-br: Análise de sentimentos de textos em português do mercado financeiro. *In*: **Anais do Brazilian Workshop on Artificial Intelligence in Finance (BWAIF)**. Porto Alegre, RS, Brasil: SBC, 2023. Disponível em: https://sol.sbc.org.br/index.php/bwaif/article/view/24960.